

Semestrální projekt SCP

David Jedlička

3eMAI/1

Popis programu

Jedná se o jednoduchý program, který umí klasifikovat zvolený text podle zadaných klasifikačních tříd nebo „vygenerovat“ klíčová slova. Program ctí zásady OOP. Program pracuje jen s jednou třídou `KlasifikaceTextu`. Dědění z rodičovské třídy mi pro tento příklad nepřišlo úplně potřebné, ikdyž by tu šlo udělat. Třída obsahuje všechny potřebné metody pro načítání textu a tříd, výpis výsledků a klasifikaci textu. Všechny metody mají přístupové právo `public`, proměnné třídy pak `private`, aby je uživatel nemohl měnit. Více viz. soubor `KlasifikaceTextu.h`.

Spouštění

Program je možné spouštět buď pomocí souboru `Klasifikace.exe` nebo z příkazové řádky.

Jestliže se uživatel rozhodne spouštět program z příkazové řádky, tak má na výběr, zda zadá argumenty či nikoli. Jako první argument je zadáván název souboru s textem, jako druhý argument název souboru s klasifikačními třídami.

Chod programu

Pokud uživatel zvolí spouštění pomocí souboru `Klasifikace.exe`, tak se mu jako první zobrazí jednoduché základní menu, které může ovládat pomocí čísel příslušící pořadím voleb menu. Jako první má uživatel zvolit, jak chce zadávat text. Má na výběr buď načtení ze souboru nebo zadáním textu do příkazového řádku. Po zadání textu je uživatel dotázán, jakým způsobem chce zadávat klasifikační třídy, nebo zda chce vygenerovat klíčová slova. Třídy se mohou zadávat stejným způsobem jako text. Následně je uživatel vyzván k zadání úroveň klasifikace. To je takové číslo, podle kterého program rozhoduje, zda daný text bude spadat do nějaké klasifikační třídy. Nechtěl jsem zadávat nějakou hodnotu na pevně, ale ať má uživatel na výběr. Doporučuji zadávat hodnotu alespoň 2. Následně proběhne výpis výsledků na konzoli.

Pro spouštění programu z příkazové řádky má uživatel na výběr, zda zadá jeden nebo žádný argument nebo dva argumenty. Pokud je zadán jeden nebo žádný argument, tak program probíhá stejně jako v případě spouštění pomocí `Klasifikace.exe`. Jestliže jsou zadány 2 argumenty, tj. názvy souborů textu a klasifikačních tříd, tak program se už nedotazuje, na způsoby zadávání textu a klasifikačních tříd. Zeptá se rovnou na zadání úrovně klasifikace. Po zadání proběhne opět výpis na konzoli.

Po vypsání na konzoli je možnost nechat si výsledky uložit do souboru. Následně se program vrací na začátek, kde uživatel může zadat jiný text nebo program ukončit.

Pozn.1 Pokud je zadáváný text v češtině, tak zadávat bez diakritiky.

Pozn.2 Možnost vygenerovat klíčová slova je jen pro text v angličtině nebo v češtině. Viz. dále

Metody třídy

Načítání textu a tříd

`void nactiTextSoubor()` – Metoda, která slouží k načítání textu ze souboru. Pokud není zadán správný název souboru, tak se ptá dokola, dokud nebude zadán správný název. Metoda vždy načte jeden řádek textu ze souboru. Poté převede všechna velká písmena z načteného řádku na malá a odstraní veškerou interpunkci. Pokud možno zadávat text bez diakritiky.

void nactiText() – Metoda pro načítání textu z klávesnice. Zadávaný text může obsahovat prázdné řádky. Přečtu jeden řádek textu, opět převedu všechna velká písmena na malá a odstraním interpunkci. Načítání je ukončeno zadáním ctrl+z na prázdný řádek. Pokud možno zadávat text bez diakritiky.

void nactiTridySoubor() – Metoda pro načítání tříd ze souboru. Třídy mohou být v souboru napsané zvlášť každá na jednom řádku nebo v jednom řádku oddělené čárkou a mezerou, např. třída1, třída2. Pokud není zadán správný název souboru, tak se metoda ptá, dokud není zadán správný název. Ze souboru načtu jeden řádek, převedu velká písmena na malá, odstraním oddělující čárky, pokud jsou tak zapsané v souboru a uložíím načtený řádek do pomocného vektoru tridy_[]]. Poté načtený řádek rozdělím na jednotlivá slova a každé slovo uložíím do vektoru tridy[]].

Pozn. Nechtěl jsem, aby uživatel byl nějak limitován zapsáním tříd v souboru, proto jsem zvolil způsob, který mi tyto dva případy pokryje. I když je tu mírná limitace na oddělení slov v řádku.

void nactiTridy() – Metoda pro načítání tříd z klávesnice. Uživatel může zadávat třídy každou na vlastní řádek, nebo v jednom řádku oddělené čárkou a mezerou. Metoda funguje stejně jako metoda pro načítání tříd ze souboru. Načítání je opět ukončeno zadáním ctrl+z na prázdný řádek.

void nactiStopWords() – Metoda, která načítá spojky, předložky a další podobná slova, která nemají nějaký význam. Načítání je ze souboru, který uživatel nezadáva, je pevně dán. Tyto slova načítám pouze pokud budeme chtít vygenerovat klíčová slova, protože je pak chci při generování klíčových slov odstranit. Pokud bych je neodstranil, tak by klíčová slova nedávala moc smysl. Pro hledání klíčových slov pracuje program pouze se dvěma jazyky. Angličtinou a češtinou. Nebyl by problém to rozšířit i o další jazyky, ale musel by se lehce upravit kód. Hledání klíčových slov jsem v programu zvolil jako další využití metody bag of words a pro ukázkou jsem zvolil tyto dva jazyky.

Výpis a zápis výsledků

Třída obsahuje metody pro výpis, které jsem používal pro kontrolu, zda se mi správně načítal text, třídy, apod. V programu jinak využívány nejsou, pouze metoda pro výpis vygenerovaných klíčových slov je používána v programu. Metoda **void ulozDoSouboru()** slouží pro ukládání do souboru. Do souboru se uloží přesně to, co se vypíše na konzoli.

Další metody

void setUroven() – Metoda, která slouží k zadávání úrovně klasifikace. Je nutno zadávat přirozené číslo.

Pozn. Nechtěl jsem zadávat nějakou hodnotu napevno, ať si může uživatel rozhodnout sám.

void BagOfWords() – Metoda slouží k rozdělení načtených a upravených řádků na jednotlivá slova. Následně spočítá kolikrát se daná slova v textu vyskytují. Metoda obsahuje i cyklus, který z textu odstraňuje spojky, předložky a podobná slova. Odstranění probíhá pouze pro generování klíčových slov.

void klasifikuj() – Metoda, která slouží pro klasifikaci textu. Funguje tak, že vezmu každou třídu klasifikace a v textu, který je už rozdělen na jednotlivá slova, hledám slovo, které má stejný „kořen“. Pokud takové slovo najdu, tak třídě přiřadím hodnotu, která vyjadřuje počet výskytů nalezeného slova v textu. Když takové slovo nenajdu, tak ještě od třídy odeberu několik posledních písmen a zkusím prohledat text znovu. Tohle zkusím z toho důvodu, že pro třídu celebration a slovo celebrate by první část nedávala správný výsledek, i když toto slovo patří do této třídy.

Následně projdu hodnoty výskytu všech tříd a podle toho, zda jsou větší nebo rovny zadané úrovni klasifikace je prohlásím za klasifikační třídy daného textu.

void argumenty(string, string) - Metoda pro načítání textu a tříd, kde jako parametry metody vstupují argumenty příkazového řádku. Argumenty jsou název souboru s textem a název souboru s třídami. Načítání pak probíhá stejně u načítání textu a tříd ze souboru.

Shrnutí

Program umí klasifikovat text podle daných klasifikačních tříd nebo najít klíčová slova textu. Je jazykově nezávislý, až na hledání klíčových slov.